ВЫЧИСЛИТЕЛЬНЫЕ МЕТОДЫ · ЛЕКЦИЯ 8

Современные методы вычислительной физики

Суррогатные модели, PINN и машинно-обученные межатомные потенциалы

Лю Шисян

Кафедра теплофизики (Э6)
МГТУ им. Н.Э. Баумана
Москва / 2026

Место этой лекции в курсе



Машинное обучение в физических моделях

Три задачи: прогноз физических свойств, решение уравнения теплопроводности и расчёт фононов с готовым межатомным потенциалом.

План

1. Суррогатные модели
2. Физически-информированные нейронные сети
3. Машинно-обученные межатомные потенциалы
4. Расчёт фононов и итоги

1

Суррогатные модели

Суррогатная модель расчёта

Традиционный расчёт

Для каждого нового набора параметров нужно заново запускать

FEM / MC / DFT / эксперимент.

Это может занимать минуты, часы или значительно больше.

Например:

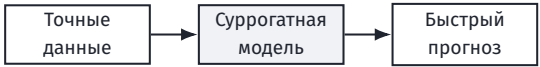
$$(T, L, \eta) \longrightarrow \text{MC} \longrightarrow \kappa.$$

Суррогатная модель

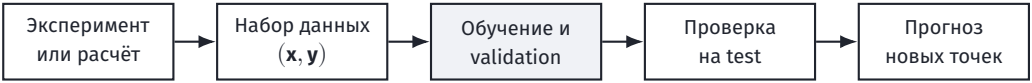
Сначала строим ограниченный набор точных данных, а затем обучаем модель приближать отображение

$$\mathbf{x} \longrightarrow \mathbf{y}.$$

После обучения новый прогноз выполняется очень быстро.



Данные и обучение суррогата



Входы

Геометрия, температура, состав, параметры режима:

$$\mathbf{x} = (T, L, W, \eta, ...).$$

Выход

Физическое свойство:

$$\mathbf{y} = (\kappa, C_v, ...).$$

Покрытие обучающих данных

Обучающие данные должны покрывать диапазон параметров, в котором будет использоваться модель.

Пример: прогноз теплопроводности

В учебном примере используются два входа:

$$T,\ L$$

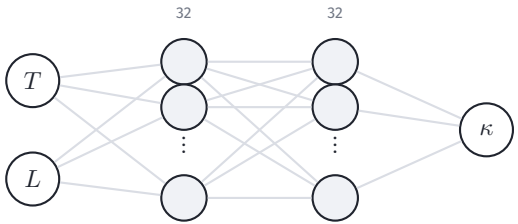
и один выход:

$$\kappa.$$

Архитектура

$$2 \to 32 \to 32 \to 1$$

Два скрытых слоя с ReLU, линейный выход. Loss — MSE для $\kappa/100$.



Прогноз теплопроводности

После обучения можно быстро оценивать

$$\kappa(T, L)$$

для новых точек внутри изученного диапазона.

Данные для регрессии теплопроводности

$$\kappa(T, L) = \frac{200}{1 + 0.0005(T - 300)^2} \exp(-L/200).$$

1000 искусственных наблюдений

- $T \in [100, 600]$ K;
- $L \in [10, 500]$ nm;
- генератор NumPy: seed 0;
- κ в условных W/(m K).

Случайное разбиение

- 700 объектов — train;
- 150 — validation: выбор эпохи;
- 150 — test: итоговая ошибка.

Входы приводим к диапазону $[0, 1]$, выход делим на 100.

Это учебная функция, а не закон для Si и не данные Monte Carlo.

Суррогатная модель на PyTorch

```
class KappaNet(nn.Module):
    def __init__(self):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(2, 32), nn.ReLU(),
            nn.Linear(32, 32), nn.ReLU(), nn.Linear(32, 1)
     )

    def forward(self, x):
        return self.net(x)
```

Обучение

- ReLU в двух скрытых слоях;
- Adam, $\eta = 10^{-3}$;
- 2000 эпох, batch 64;
- seed PyTorch: 0.

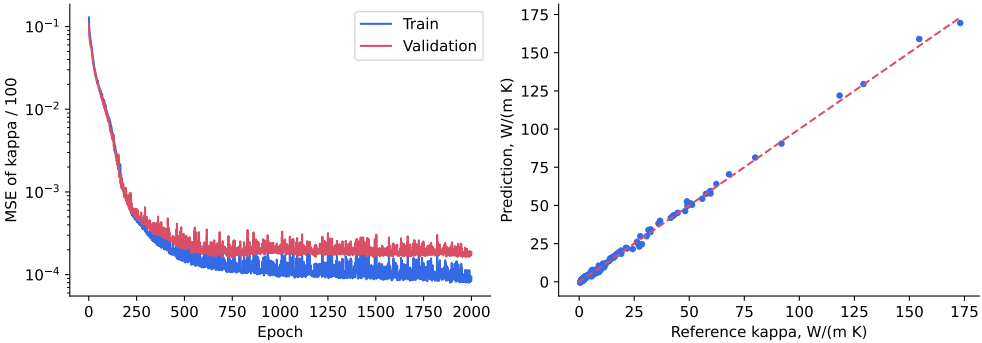
После обучения восстанавливаем веса с минимальным validation loss.

Один шаг обучения

```
for batch in torch.tensor(train)[torch.randperm(len(train))].split(64):
    loss = ((model(X[batch]) - y[batch])**2).mean()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
```

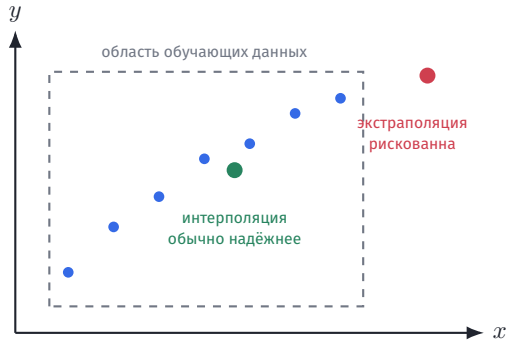
1. Вычисляем прогноз и MSE для batch.
2. Обнуляем накопленные градиенты.
3. Вычисляем новые градиенты и обновляем веса.

Теплопроводность: результат на test



Выбрана эпоха 747. На 150 тестовых объектах: RMSE $= 1.296$, MAE $= 0.921$ W/(m K).

Интерполяция и экстраполяция



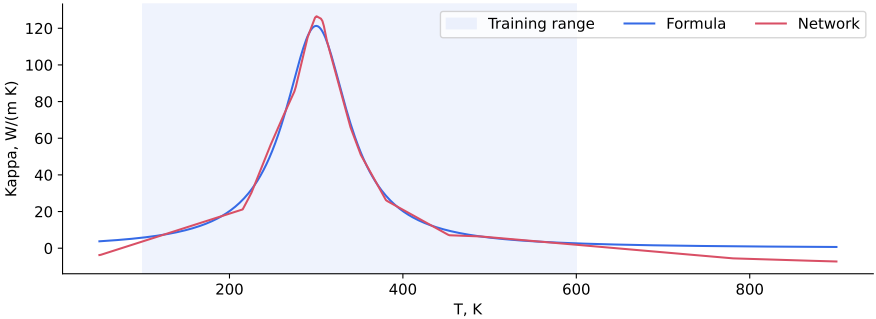
Интерполяция

Новая точка находится внутри области, покрытой обучающими примерами.

Экстраполяция

Модель используется за пределами известных данных.
Здесь ошибка может резко возрасти.

Что происходит при экстраполяции



$L = 100$ nm. Голубая область — диапазон температур обучающих данных.

За его пределами сеть даёт в том числе отрицательные значения κ.

2

Физически-информированные нейронные сети

Обучение по данным и физическим уравнениям

Обычная нейросеть

Учится на парах данных:

$$\mathbf{x}_i \to \mathbf{y}_i.$$

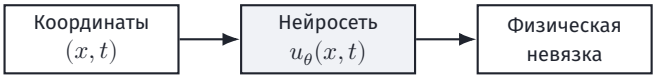
Физический закон явно не используется:

$$\mathcal{L} = \mathcal{L}_{\text{data}}.$$

Physics-Informed NN

Кроме данных, известны уравнения и условия задачи.
Они добавляются в loss:

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \mathcal{L}_{\text{physics}}.$$



Пример: одномерная теплопроводность

Безразмерная задача для сравнения трёх методов

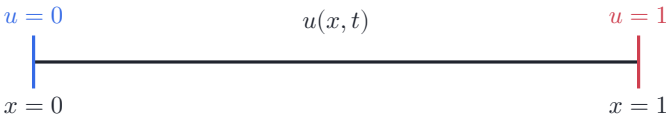
$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2}, \qquad x \in (0,1), \quad 0 < t \leq 0.4.$$

Начальное условие

$$u(x,0) = x + \sin(\pi x).$$

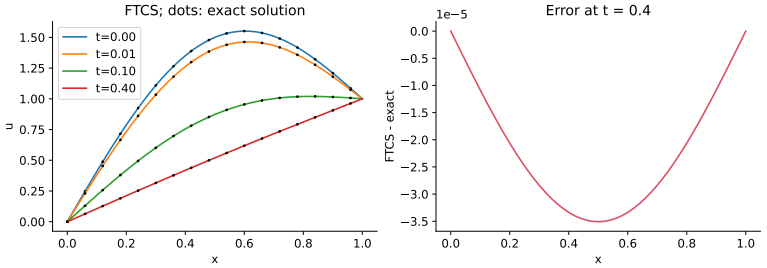
Граничные условия

$$u(0,t) = 0, \qquad u(1,t) = 1.$$



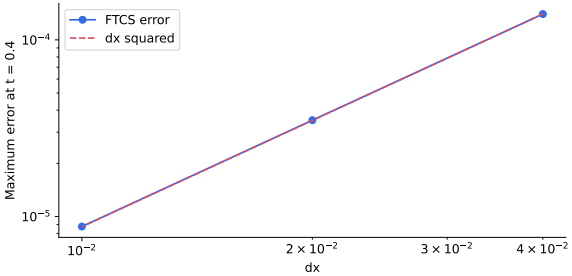
Эталон: точное решение и конечные разности

$$u(x,t) = x + e^{-\pi^2 t}\sin(\pi x), \qquad u_i^{n+1} = u_i^n + r(u_{i+1}^n - 2u_i^n + u_{i-1}^n).$$



FTCS: 51 узел, $r = \Delta t/\Delta x^2 = 0.4 \le 1/2$. При $t = 0.4$: максимальная ошибка $3.51 \cdot 10^{-5}$.

Проверка сходимости FTCS



Сравнение при $t = 0.4$

Узлы	Максимальная ошибка
26	$1.40 \cdot 10^{-4}$
51	$3.51 \cdot 10^{-5}$
101	$8.77 \cdot 10^{-6}$

При уменьшении Δx вдвое ошибка уменьшается примерно в 4 раза.

$r = 0.4$ сохраняем во всех расчётах.

PINN: гладкая сеть и автоматические производные

Сильная форма уравнения теплопроводности

Для $u_\theta(x, t)$ вычисляем

$$u_t = \frac{\partial u_\theta}{\partial t}, \qquad u_{xx} = \frac{\partial^2 u_\theta}{\partial x^2}, \qquad r = u_t - u_{xx}.$$

Автоматическое дифференцирование применяет цепное правило к операциям сети.

Гладкость функции активации

Для u_{xx} нужна вторая производная по входу. У сети с ReLU она равна нулю почти всюду, поэтому здесь используем Tanh.

Архитектура PINN: три скрытых слоя по 32 нейрона с Tanh.

Невязка уравнения в PyTorch

```python
def residual(model, points):
    xt = points.detach().clone().requires_grad_(True)
    u = model(xt)
    grad = torch.autograd.grad(u, xt, torch.ones_like(u), create_graph=True)[0]
    u_x, u_t = grad[:, :1], grad[:, 1:2]
    u_xx = torch.autograd.grad(u_x, xt, torch.ones_like(u_x), create_graph=True)[0][:, :1]
    return u_t - u_xx
```

Столбцы `xt`: x, затем t. `create_graph=True` сохраняет граф для вторых производных и обучения.

Функция потерь PINN

Уравнение и начальное условие

$$L_{\text{PDE}} = \text{mean}\big[(u_t - u_{xx})^2\big],$$

$$L_{\text{IC}} = \text{mean}\big[(u_\theta(x,0) - u_0(x))^2\big].$$

512 внутренних точек; 64 точки при $t = 0$.

$$u_0(x) = x + \sin(\pi x).$$

Две границы

$$L_{\text{BC}} = \tfrac{1}{2}\big[\,\text{mean}\big[u_\theta(0,t)^2\big] + \text{mean}\big[(u_\theta(1,t) - 1)^2\big]\big].$$

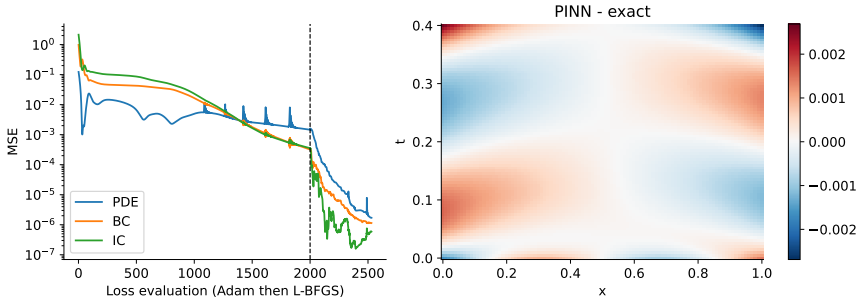
По 64 точки на каждой границе.

Начальное и граничные условия согласованы.

$$L = L_{\text{PDE}} + L_{\text{BC}} + L_{\text{IC}}.$$

Adam: 2000 эпох, $\eta = 10^{-3}$; затем L-BFGS: до 500 итераций.

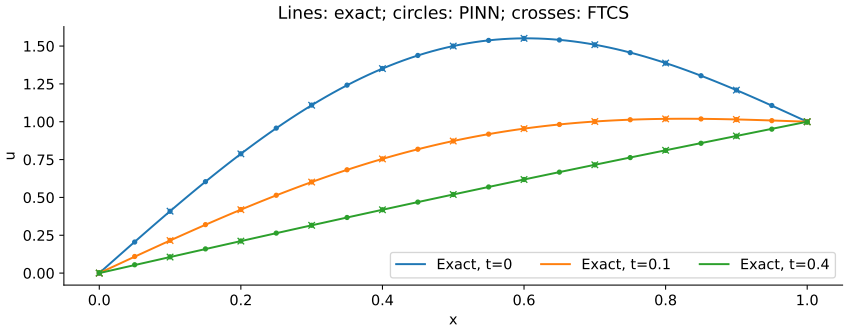
PINN: обучение и ошибка решения



Независимая сетка 101×81: RMSE $5.42 \cdot 10^{-4}$, максимум $2.69 \cdot 10^{-3}$.

После пунктирной линии по оси абсцисс считаются вызовы loss в L-BFGS.

PINN, FTCS и точное решение



Линии — точное решение; кружки — PINN; крестики — FTCS.

Внутренние значения точного решения не использовались для обучения PINN.

Преимущества и ограничения PINN

Преимущества

- физика входит прямо в процесс обучения;
- можно использовать редкие или шумные данные;
- неизвестные физические параметры можно обучать вместе с сетью;
- решение задаётся непрерывной функцией $u_\theta(x, t)$.

Ограничения

- обучение может быть трудным и медленным;
- разные компоненты loss имеют разные масштабы;
- сложны stiff, multiscale и высокочастотные задачи;
- малый loss требует отдельной проверки точности решения.

3

Машинно-обученные межатомные потенциалы

Энергия и силы в молекулярной динамике

Движение атомов определяется уравнением Ньютона:

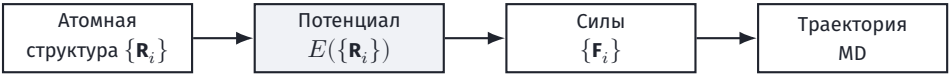
$$m_i \ddot{\mathbf{R}}_i = \mathbf{F}_i.$$

Но силы связаны с потенциальной энергией:

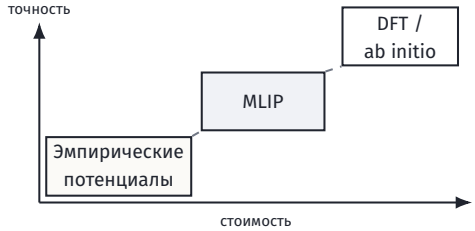
$$\mathbf{F}_i = -\frac{\partial E}{\partial \mathbf{R}_i}.$$

Следовательно, ключевой объект атомистического моделирования —

$$E(\mathbf{R}_1, \mathbf{R}_2, \dots, \mathbf{R}_N).$$



DFT, эмпирические потенциалы и MLIP



Эмпирические потенциалы

- очень быстрые;
- аналитическая форма задаётся заранее;
- ограниченная гибкость.

DFT

- высокая точность;
- используется для получения reference data;
- высокая вычислительная стоимость.

MLIP

- обучаются на reference data;
- существенно быстрее DFT;
- способны описывать сложные зависимости.

Обучение межатомного потенциала



Конфигурации для обучения

Конфигурации при разных температурах и деформациях, с дефектами и поверхностями, включая неравновесные состояния.

Область применимости

MLIP надёжен только в той области конфигурационного пространства, которая достаточно представлена в обучающих данных.

Основные семейства MLIP

Локальные дескрипторы

Сначала локальное окружение атома переводится в набор признаков.

Примеры:
BPNN, GAP, MTP, ACE, NEP.

Message passing

Информация передаётся между соседними атомами по графу.

Пример:
SchNet и родственные модели.

Эквивариантные модели

Архитектура явно учитывает преобразования вращения и геометрию.

Примеры:
NequIP, MACE: также используют передачу сообщений.

NEP: дескрипторы и атомная энергия

Для атома i строится набор локальных дескрипторов

$$\mathbf{q}_i = (q_1^{(i)}, q_2^{(i)}, \dots, q_{N_{\text{des}}}^{(i)}).$$

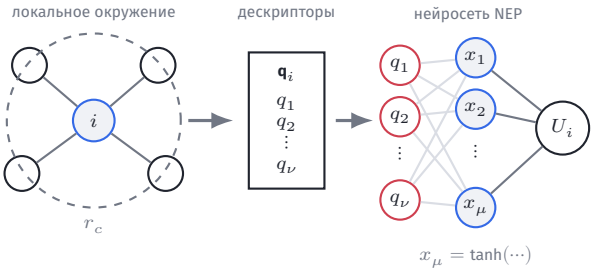
Они подаются в нейронную сеть NEP:

$$\mathbf{q}_i \longrightarrow \mathbf{x}_i \longrightarrow U_i.$$

Здесь $\mathbf{x}_i$ — выходы скрытого слоя после функции активации tanh.

Полная энергия системы:

$$E = \sum_i U_i.$$



Силы определяются как

$$\mathbf{F}_i = -\frac{\partial E}{\partial \mathbf{R}_i}.$$

NEP: радиальные и угловые дескрипторы

Радиальная информация

Расстояния до соседних атомов:

$$q_n^i = \sum_{j \neq i} g_n(r_{ij}).$$

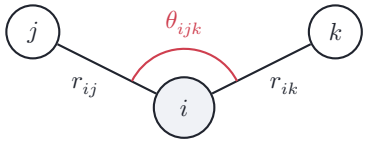
Описывает, **на каких расстояниях** находятся соседи.

Угловая информация

Геометрия троек атомов:

$$q_{nl}^i = \sum_{j \neq i} \sum_{k \neq i} g_n(r_{ij}) g_n(r_{ik}) P_l(\cos \theta_{ijk}).$$

Описывает, **как расположены** соседи вокруг атома.

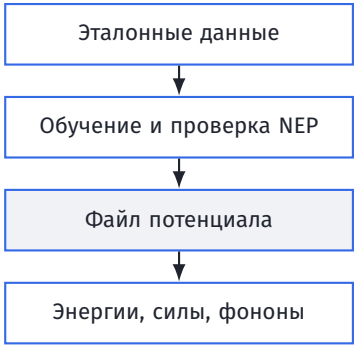


Обучение NEP и использование готового потенциала

При обучении

- конфигурации и эталонные энергии;
- силы на атомах;
- при наличии — вириалы;
- отдельная проверочная выборка.

$$L = \lambda_E L_E + \lambda_F L_F + \lambda_V L_V + L_{\text{reg}}.$$



В Notebook используем готовый `Si_NEP.txt`; новое обучение NEP не выполняется.

4

Расчёт фононов и итоги

Практика: структура и потенциал Si

```
structure = read(data / "POSCAR-Si")
calculator = CPUNEP(str(data / "Si_NEP.txt"))
structure.calc = calculator
initial_volume = structure.get_volume()
relax_structure(structure, fmax=1e-4, logfile=None)
```

Исходные файлы

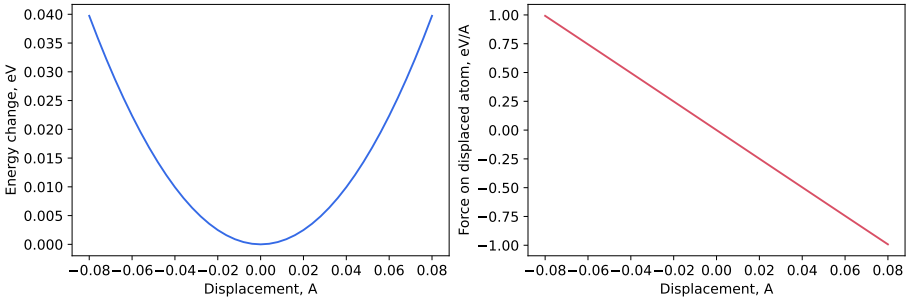
- `data/POSCAR-Si`: 2 атома;
- `data/Si_NEP.txt`: NEP3;
- `data` — путь к папке данных.

Релаксируем координаты и ячейку.

Объём: $40.105 \to 40.630$ Å^3.

Максимальная сила меньше 10^{-4} eV/Å.

Проверяем связь энергии и силы

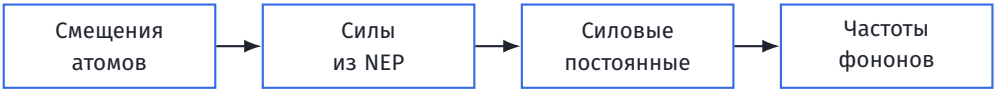


Смещаем один атом суперячейки $2 \times 2 \times 2$. При смещении 0.02 Å: $F_x = -0.248551$ eV/Å.

Центральная разность энергии даёт ту же силу с расхождением $2.3 \cdot 10^{-10}$ eV/Å.

От сил к силовым постоянным

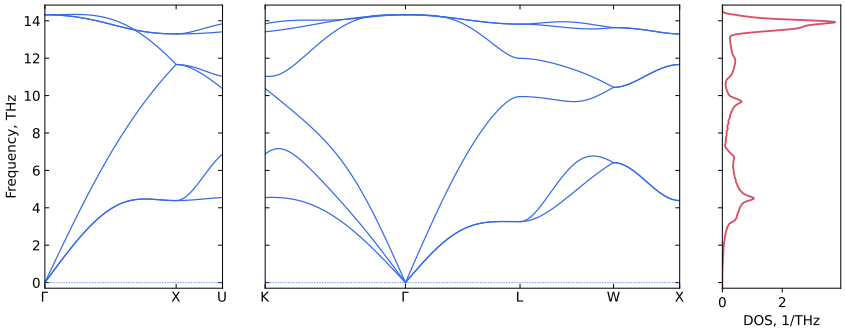
```
phonon = get_force_constants(structure, calculator, [4, 4, 4],
    kwargs_generate_displacements={"distance": 0.01})
```



$4\times4\times4$ примитивные ячейки: 128 атомов; смещение 0.01 Å.

После расчёта применяем симметризацию и акустическое правило сумм.

Si: дисперсия и плотность фононных состояний



2 атома в примитивной ячейке $\Rightarrow$ 6 ветвей: 3 акустические и 3 оптические.

DOS: сетка 30^3, гауссово уширение 0.08 THz; интеграл равен 6.

Проверки фононного расчёта

Проверка	Результат для Si_NEP.txt
Акустические частоты в Γ	Менее $4 \cdot 10^{-7}$ THz
Оптические частоты в Γ	Около 14.323 THz
4^3 и 5^3, три выбранных q-точки	Разница менее 10^{-6} THz
Энергия и сила	Согласованы с численной производной

Это проверки данного расчёта. Сравнение с DFT или экспериментом требует отдельных данных.

Для исследования также проверяют величину смещения и плотность q-сетки.

Итоги лекции

01 **Суррогат**: обучаем прогноз по данным, отделяем validation и test.

02 **PINN**: используем уравнение и условия, проверяем ошибку решения.

03 **NEP**: вычисляем энергии и силы, получаем фононный спектр.

github.com/lyushisyan/computational-methods-course

`08-modern-computational-physics`